电子科技大学

计算机专业类课程

实验报告

课程名称:数据挖掘与大数据分析

学 院: 计算机科学与工程学院

专 业: 计算机科学与技术

学生姓名: 岳子豪

学 号: 2018051404015

指导教师: 邵俊明

日期: 2021年9月11日

电子科技大学实验 报告

- 一、实验名称:数据预处理
- 二、实验学时: 4
- 三、实验内容和目的:
- 1. 安装并配置 Python、Pycharm 和 Weka
- 2. 使用图形界面的 Weka 工具包,完成数据归一化、缺失值处理、特征筛选的数据预处理操作
- 3. 在 Pycharm 下调用 numpy、pandas 和 Counter 包,完成数据归一化、缺失值 处理、特征筛选的数据预处理操作

四、实验原理:

1. 数据属性最小最大归一化。

$$v' = \frac{v - min_A}{max_A - min_A} (new _ max_A - new _ min_A) + new _ min_A$$

其中 v 是属性 A 的某个观测值,minA 和 maxA 分别是属性 A 的最小值和最大值。上述公式将 A 属性的取值映射到区间[new_minA,new_maxA],如果令 $new_maxA = 1$, $new_minA = 0$,则将 A 属性映射到区间[0,1],实现了数据归一化。

- 2. 缺失值处理。对于数据中属性的缺失值,使用该属性的平均值来填补缺失值。
- 3. 特征筛选。信息增益是用来进行特征筛选的常用算法,基本思想是选择那些特征对分类变量 Y 信息增益大,删除那些对分类无用的特征。

五、实验器材(设备、元器件)

- 1. 笔记本 1 台, 系统 Windows 11
- 2. Python 3.9 Pycharm 2021.2 Weka 3.8.5

六、实验步骤:

- 1. 使用 Weka 对 iris.arff 进行归一化处理, filter 使用 Normalization, 参数默认。
- 2. 新建 experiment1_normalization.py 并编写 Python 代码,如下:

```
import numpy as np
import pandas as pd
def loadIris(address):
   spf = pd.read_csv(address, sep=', ', index_col=False, header=None)
   strs = spf[4]
   spf.drop([4],axis=1,inplace=True)
   return spf.values,strs
def normalization(data_matrix):
   e = 1e-5
   for c in range(4):
       maxNum = np.max(data_matrix[:,c])
       minNum = np.min(data_matrix[:,c])
        data_matrix[:,c] = (data_matrix[:,c] - minNum + e)/(maxNum - minNum +e)
    return data matrix
if __name__ == '__main__':
   filepath = 'iris.arff'
   writepath = 'iris normal.txt'
   # read data
   data_matrix,str_name = loadIris(filepath)
   # normalization
    data_matrix = normalization(data_matrix)
```

```
spf = pd.DataFrame(data_matrix)
strs = str_name.values
spf.insert(4,4,strs)
spf.to_csv(writepath,index=False,header=False)
```

运行该程序,对 iris.arff 进行处理,程序将结果写入 iris_normal.txt。 再使用图形界面的 Weka 工具包对 iris.arff 进行处理,将处理后的结果保存在 iris_normal(GUI).arff 中,对比 iris_normal.txt 与 iris_normal(GUI).arff 中的内容,

- 3. 使用 Weka 图形界面工具完成数据缺失值处理,数据使用 labor.arff, fil 使用 ReplaceMissingValues,参数默认。
- 4. 新建文件缺失值处理.py,并编写 Python 代码,如下:

比较通过两种不同方法对数据进行归一化操作后的结果。

```
import numpy as np
import pandas as pd
from collections import Counter
def loadLabor(address):
   spf = pd.read_csv(address, sep=', ', index_col=False, header=None)
    column=['duration','wage-increase-first-year','wage-increase-second-year',
'wage-increase-third-year','cost-of-living-adjustment','working-hours', 'pension',
'standby-pay',
'shift-differential','education-allowance','statuory-holidays','vaction','longterm-
disability-assistance', 'contribution-to-dental-plan',
'bereavement-assistance','contribution-to-health-plan','class']
   spf.columes = column
   # Label data
   str_typeName = ['cost-of-living-adjustment', 'pension', 'education-allowance','
vacation ', 'longterm-disability-assistance' ,'contribution-to-dental-plan','
bereavement-assistance', 'contribution-to-health-plan ', 'class ']
    str2numeric = {}
   str2numeric['?'] = '-1'
    spf = spf.replace(str2numeric)
   return spf, str2numeric, str_typeName
def fillMissData(spf, str2numeric):
   row, col = spf.shape
   columns = spf.columns
   for column name in columns:
```

```
if column_name not in str2numeric:
       # number, "first stretegy
           tmp = spf[column_name].apply(float)
           ave = np.average(tmp[tmp != -1])
           tmp[tmp== -1]= ave
           spf[column_name] = tmp
       else:
       # label, second stretegy
           v = spf[column name].values
           v1 = v[v != '-1']
           c = Counter(v1)
           cc = c.most\_common(1)
           v[v=='-1'] = cc[0][0]
       return spf
if name == ' main ':
   filepath = 'labor.arff'
   fillFilepath = 'laborMissing handle.txt'
    spf, str2numeric, str2numeric = loadLabor(filepath) # load dataspf =
fillMissData(spf, str2numeric) # fill missing data
    spf = fillMissData(spf,str2numeric)
    spf.to_csv(fillFilepath, index=False,header = False) # save data
```

运行该程序,将结果写入 laborMissing_handle.txt。

- 5. 使用 Weka 图形界面工具完成特征筛选,数据使用 iris.arff, filter 使用 AttributeSelection, 其中参数 evaluator 选择 InfoGainAttributeEval, search 使用 Ranker, 调节 Ranker 的参数为 4。
- 6. 新建文件特征筛选.py,并编写 Python 代码如下:

```
import numpy as np
import pandas as pd
from collections import Counter

def loadIris(address):
    spf = pd.read_csv(address,sep=',',index_col=False,header=None)
    strs = spf[4]
    spf.drop([4],axis=1,inplace=True)
    return spf.values,strs

def featureSelection ( features, label) :
    featureLen = len( features[0,: ])
```

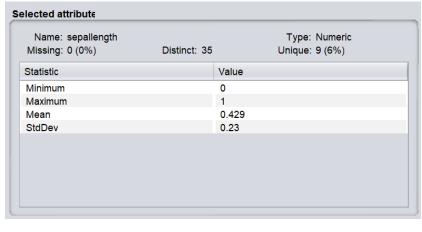
```
label_count = Counter(label)
   samples_energy = 0.0
   data_len = len(label)
   for i in label_count.keys() :
       label_count[i]/= float(data_len)
    samples_energy -= label_count[i] * np.log2(label_count[i])
    informationGain = []
   for f in range(featureLen): # computing energy for each fea#discretize: 10
       af = features [ :, f]
       minf = np.min(af)
       maxf = np.max(af) + 1e-4
       width = (maxf - minf) /10.0
       d = (af - minf) / width# dividing data
       dd = np.floor(d)
       c = Counter(dd)
       sub_energy = getEnergy(c,dd,label)
       informationGain.append( samples_energy - sub_energy)
   return informationGain
def getEnergy(c, data,label):
   dataLen = len (label)
   energy = 0.0
   #dataLen = len ( data)
   for key, value in c.items ( ):
       c[key] /=float(dataLen)
       label_picked = label[data == key]
       1 = Counter(label_picked)
       e = 0.0
       for k, v in l.items( ):
           r = v/float(value)
           e -= r* np.log2(r)
       energy += c[key] * e
   return energy
if __name__ == '__main__':
   filepath = 'iris.arff'
   #read data
   data_matrix, str_name = loadIris(filepath)
    informationGain = featureSelection(data_matrix, str_name.values)
    print( informationGain)
```

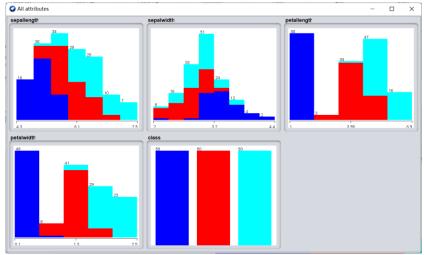
7. 运行该程序,观察运行结果。

七、实验数据及结果分析:

1. 归一化

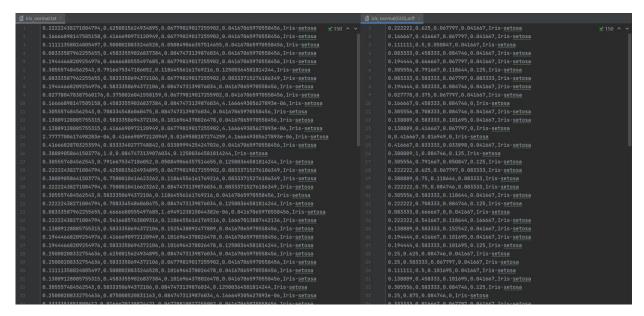
使用 Weka 工具包对数据进行归一化处理,结果如下:





可以看出,数据各个属性的值已经归一化到[0,1]。

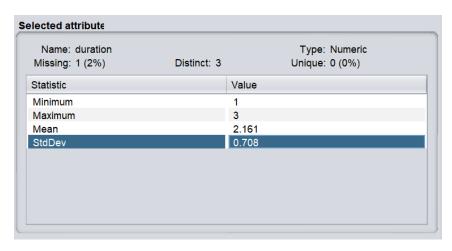
使用 Python 对数据进行归一化之后的结果与使用 Weka GUI 工具包处理后的结果对比如下:

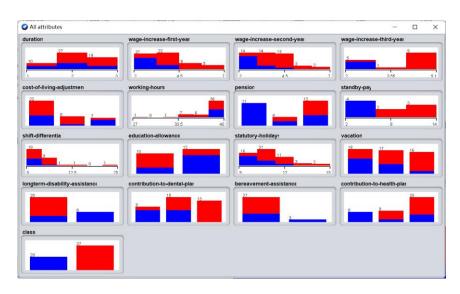


可见,在一定精度范围内,两种方法对数据进行归一化预处理的结果相同。

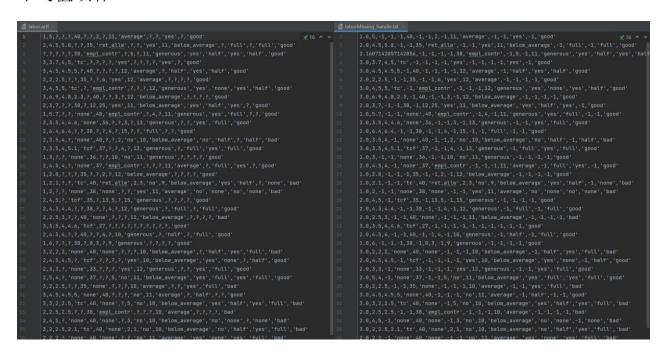
2. 缺失值处理

使用 Weka 对 labor.arff 进行缺失值处理,ReplaceMissingvalues 之后的结果如下:



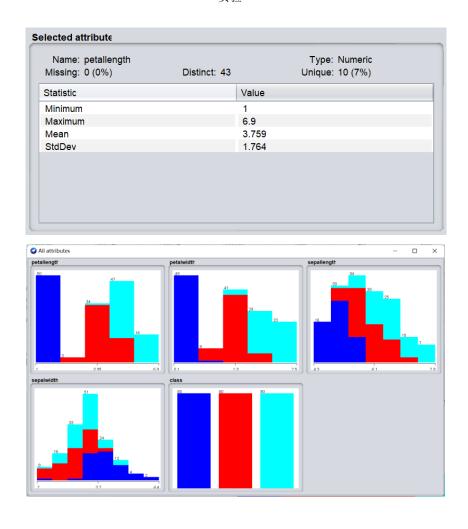


观察处理前后的数据,可以看出,数据中属性的缺失值,已经被该属性的平均值填补。



3. 特征筛选

使用 Weka 对 iris.arff 进行特征筛选,将最大特征数目设定为 4,结果如下:



Python 程序运行结果如下:



八、实验结论、心得体会和改进建议:

1. 实验结论:

本实验通过 python 调用 numpy、pandas、Counter 包,完成了数据归一化、缺失值处理、特征筛选等数据预处理操作。使用 Python 预处理的数据与使用图形界面的 Weka 工具包处理后得到的结果一致。

2. 心得体会:

本实验帮助我对数据预处理的基本知识和意义有了更深刻的认识,通过实践,对数据预处理的操作有了基本的掌握,为后续的实验打好了基础。

3. 改进建议:

无。

电子科技大学实验报告

- 一、实验名称: 关联数据挖掘
- 二、实验学时: 4
- 三、实验内容和目的:
- 1. 掌握关联规则挖掘的基本概念、原理和一般方法
- 2. 掌握 Apriori 算法

四、实验原理:

- 1. 挖掘关联规则一般步骤
 - (1) 频繁项集产生(Frequent Itemset Generation)

其目标是发现满足最小支持度阈值的所有项集,这些项集称作频繁项集。

(2) 规则的产生(Rule Generation)

其目标是从上一步发现的频繁项集中提取所有高置信度的规则,这些规则称作强规则(strong rule)。

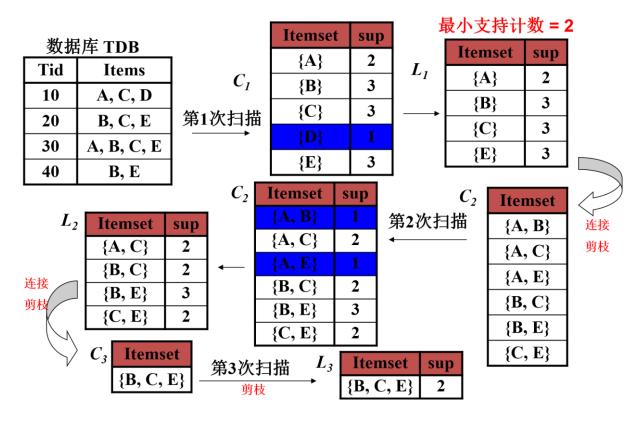
2. Apriori 算法

性质一: 如果一个项集是频繁的,则它的所有子集一定也是频繁的

性质二:相反,如果一个项集是非频繁的,则它的所有超集也一定是非频

繁的

3. Apriori 算法



五、实验器材(设备、元器件)

笔记本 1 台,系统 Windows 11

Python 3.9、Pycharm 2021.2 、 Weka 3.8.5

六、实验步骤:

- 1. 新建 main.py;
- 2. 定义 Apriori 类,包括初始化和函数操作;

```
class Apriori:
    # transition set
    traDatas = []
    # transition set's length
    traLen = 0
    # frequent k set, start with 1
```

```
k = 1
   # counting the number of transition set
   traCount = {}
   # store frequent transition
   freTran = {}
   # support
   sup = 0
   # confidence
   conf = 0
   freAllTran = {}
   def __init__(self, traDatas, sup, conf):
       self.traDatas = traDatas
       self.traLen = len(traDatas)
       self.sup = sup
       self.conf = conf
   def scanFirDatas(self): # count frequency for each element
       tmpList = ','.join(traDatas).split(',')
       tmpSetList = [(each,) for each in tmpList]
       self.traCount = dict(collections.Counter(tmpSetList))
       return self.traCount
   def getFreSet(self): # find event with higher support. and get frequent k set
       self.freTran = {}
       for tra in self.traCount.keys():
           if self.traCount[tra] >= self.sup and len(tra) == self.k:
               self.freTran[tra] = self.traCount[tra] # store frequent set
               self.freAllTran[tra] = self.traCount[tra]
   # compare if k-l elements is equal
   def cmpTwoSet(self, setA, setB) :
       setA = set(setA)
       setB = set(setB)
       if len(setA-setB) == 1 and len(setB-setA) == 1:
           return True
       else:
           return False
   def selfConn(self): # connecting events. Only an element is added.
       self.traCount = {}
       for item in itertools.combinations(self.freTran.keys(),2):# connecting event
between any two event.
           if self.cmpTwoSet(item[0], item[1]) == True: # only an element is added.
               key = item[0] + item[1]
```

```
if self.cutBranch(key) != False:
               self.traCount[key] = 0
def cutBranch(self, key): # if subKey of the event is not frequent, return false
   for subKey in list(itertools.combinations(key, self.k)):
       if subKey not in self.freTran.keys():
           return False
def scanDatas(self):# count support
   self.k = self.k + 1
   for key in self.traCount.keys():
       for tra in traDatas:
           if set(key).issubset(tuple(tra.split(','))):
               self.traCount[key] += 1
def permutation2(self, string, pre_str, container):
    if len(string) == 1:
       container.append(pre str + string)
   for idx, str in enumerate(string):
       new_str = string[:idx] + string[idx+1:]
       new_pre_str = pre_str + str
       self.permutation(new_str, new_pre_str, container)
def permutation(self, tup, pre_tup, container):
   if len(tup) == 1:
       container.append(pre_tup + tup)
   for idx, elem in enumerate(tup):
       new_tup = tup[:idx] + tup[idx+1:]
       new_pre_tup = pre_tup + (elem,)
       self.permutation(new tup, new pre tup, container)
def genAssRule(self):
   container = []
   ruleSet = set()
   for item in self.freTran.keys():
       self.permutation(item, (), container)
   for item in container:
       for i in range(1, len(item)):
           ruleSet.add((item[:i],item[i:]))
   for rule in ruleSet:
       if self.calcConfi(rule[0], rule[1]) > self.conf:
           print (rule[0],end="_--->>>")
           print(rule[1])
def calcConfi(self, first, last): #computing confidence
```

```
if first+last not in self.freAllTran.keys():
    return self.freAllTran[last+first]/self.freAllTran[first]

return self.freAllTran[first + last] / self.freAllTran[first]

def algorithm (self):
    self.scanFirDatas()# count frequency for each element
    while self.traCount != {}:
        self.getFreSet() # find event with higher support. and get frequent k set
        self.selfConn() # connecting events. Only an element is added.cut branch
        self.scanDatas() # count support
    print(self.freAllTran)
    print(self.freTran)
    self.genAssRule()# mining rules.
```

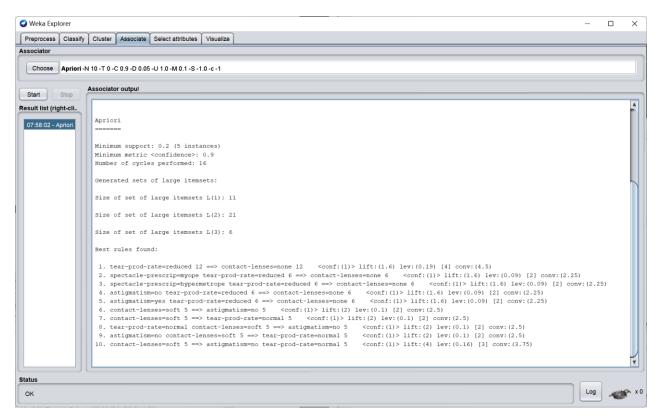
3. 主函数, 读取数据集并进行关联规则挖掘, k 设置为 2, 置信度设置为 0.7。

```
with open('contact-lenses.arff') as f:
    traDatas = []
    perline = f.readline()[:-1]
    while perline:
        traDatas.append(perline)
        perline = f.readline()[:-1]
# print(traDatas)
apriori = Apriori(traDatas, 2, 0.7)
apriori.algorithm()
```

4. 运行代码,得到实验结果。

七、实验数据及结果分析:

使用 weka 图形界面实现关联规则挖掘,结果如下:



实验结果如图所示:

```
D:\Miniconda3\python.exe D:/Desktop/数据挖籍实验/DM-Experiments/DM-Exp2/main.py
{('young',): 8, ('myope',): 12, ('no',): 12, ('reduced',): 12, ('none',): 15, ('normal',): 12, ('soft',): 5, ('yes',): 12, ('hard',): 4, ('hyuftyoung', 'myope'): 4, ('young', 'no'): 4, ('young', 'reduced'): 4, ('young', 'none'): 4, ('young', 'normal'): 4, ('young', 'soft'): 2, ('young', 'none'): 4, ('young', 'normal'): 4, ('young', 'soft'): 2, ('young', 'none',)
('reduced',)_--->>('none',)
('hard',)_--->>('myope',)
('hard',)_--->>('none',)
('soft',)_--->>('normal',)
('hard',)_--->>('normal',)
('none',)_--->>('reduced',)
```

可见,算法成功地将数据集中各个元素出现的频次统计出来,并进行了关联规则挖掘,成功找到8组关联规则。

八、实验结论、心得体会和改进建议:

通过动手实现 Apriori 算法,对关联规则挖掘的一般方法进行了初步掌握,对关联规则挖掘算法有了更深刻的理解,进一步强化了理论知识的学习,加深了自己对 Apriori 算法的印象。

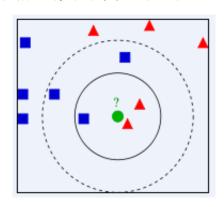
在本次实验中,遇到的最大困难是选取合适的数据结构作为元素出现频次字 典的键,由于一开始选取了元组而非集合,走了很多弯路,最终在列表、元组 与集合三种数据结构之间反复切换,总算达到了实验目标,最终顺利完成实验。 感觉在解决这个问题的过程中收获很大,除了对算法相应知识有了更进一步的 掌握,还强化了自己在 python 编程方面的技能。

- 一、实验名称:分类(KNN)
- 二、实验学时: 4
- 三、实验内容和目的:

实现 KNN 算法

四、实验原理:

KNN 属于 lazy learning,不会对训练样本数据进行学习,其做法是:对于一个新数据,计算它与训练集中数据的距离,选择最短的 k 个作为邻居,然后预测它的类别和 k 个邻居中其所属类别最多的一致。



五、实验器材(设备、元器件)

笔记本 1 台,系统 Windows 11

Python 3.9 \, Pycharm 2021.2 \, Weka 3.8.5

六、实验步骤:

- 1. 新建 classifier.py;
- 2. 读取训练集,如下:

```
import math
import re

dataset = []
dataLen = []
testDataSet = []

with open("iris.2D.train.arff") as fin:
    for line in fin.readlines():
        data = re.split(",", line.strip())
        dataLen = len(data)
        dataset.append(data)
```

3. 定义用于分类的函数, vote 函数用于投票得出标签, findNN 函数用于找到最邻近的 k 个数据, computeDis 函数用于计算几何距离。

```
def computeDis(x, y):
   return math.sqrt(math.pow(float(x[0])-float(y[0]), 2) +
math.pow(float(x[1])-float(y[1]), 2))
def findNN(testData, k):
   distances = []
   for data in dataset:
       distances.append(computeDis(testData, data))
   return (sorted(range(len(distances)), key=lambda m:distances[m]))[:k]
def vote(indexs):
   votes = {}
   for i in indexs:
       label = dataset[i][dataLen-1]
       if label not in votes.keys():
           votes[label] = 1
       else:
           votes[label] = votes[label]+1
```

```
return (max(votes, key=votes.get))
```

4. 读入测试集,通过 KNN 进行预测,并输出准确率。

```
if __name__ == "__main__":
    with open("iris.2D.test.arff") as ftest:
        for line in ftest.readlines():
            testData = re.split(",", line.strip())
            testData.append(vote(findNN([testData[0], testData[1]], 2)))
            testDataSet.append(testData)

total = 0
    right = 0

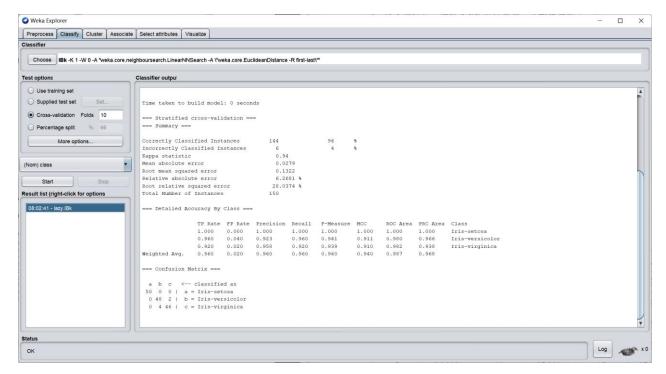
for each in testDataSet:
    total += 1
    if each[2]==each[3]:
        right += 1

print("%.2f"%(right/total*100),'%')
```

5. 运行该程序,观察运行结果。

七、实验数据及结果分析:

使用 weka 图形界面实现 KNN 分类,结果如下:



通过改变 k 值进行多次实验, 观察实验结果得到如下数据:

k	Accuracy	k	Accuracy	k	Accuracy
1	97.33%	6	96.00%	11	97.33%
2	97.33%	7	96.00%	12	97.33%
3	96.00%	8	97.33%	13	98.67 %
4	96.00%	9	97.33%	14	97.33%
5	96.00%	10	97.33%	15	97.33%

当 k=1 或 2 时,预测准确率高达 97.33%,说明分类器工作得很好;当 $k \ge 3$ 时,准确率有所降低,变为 96%,而当 k 增加到 8 时,准确率重新回到 97.33%, k=13 时,准确率达到极大值 98.67%。可见,KNN 分类的准确率跟 k 值的选取 有关,但是无明显规律。

八、实验结论、心得体会和改进建议:

通过手动实现 KNN 算法,对其原理及思路有了更深刻的理解,对其细节有了更透彻的掌握,进一步强化了理论知识的学习,加深了自己对分类算法的印象。

这个实验确实挺简单的,建议以后不用给示例代码了。

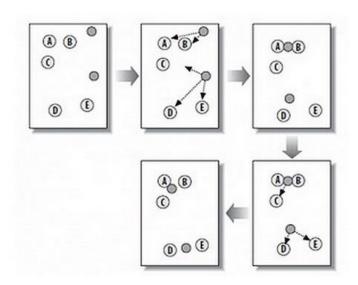
电子科技大学实验报告

实验四

- 一、实验名称:聚类实验
- 二、实验学时: 4
- 三、实验内容和目的:
- 1. 了解聚类的基本概念、原理和一般方法
- 2. 掌握聚类的基本算法
- 3. 学会调用 WEKA 包处理 kmeans 聚类问题;
- 4. 自己编程实现 K-Means、DBSCAN 算法;

四、实验原理:

- 1. K-Means 算法原理
- (1) 随机在图中取 K (如图 K=2) 个聚类中心。
- (2) 然后对图中的所有点求到这 K 个种子点的距离,假如点 Pi 离聚类中心 Si 最近,那么 Pi 属于 Si 点群。接下来,我们要移动聚类中心到属于他的"点群"的中心。
- (3) 然后重复第(2)和第(3)步,直到聚类中心几乎不发生变化。



2. DBSCAN 算法原理

通过检查数据集中每个对象的 ε -邻域来寻找聚类。如果一个点 p 的 ε -邻域包含多于 MinPts 个对象,则创建一个 p 作为核心对象的新簇。然后,DBSCAN 反复地寻找从这些核心对象直接密度可达的对象,这个过程可能涉及一些密度可达簇的合并。当没有新的点可以被添加到任何簇时,该过程结束。具体如下:输入:包含 n 个对象的数据库,半径 ε ,最少数目 MinPts。

输出: 所有生成的簇, 达到密度要求。

a. REPEAT

- b. 从数据库中抽取一个未处理过的点;
- c. IF 抽出的点是核心点 THEN 找出所有从该点密度可达的对象,形成一个簇
- d. ELSE 抽出的点是边缘点(非核心对象),跳出本次循环,寻找下一点;
- e. UNTIL 所有点都被处理;

五、实验器材(设备、元器件)

笔记本 1 台,系统 Windows 11

Python 3.9、Pycharm 2021.2 、 Weka 3.8.5

六、实验步骤:

- 1. 新建 kmeans.py;
- 2. 加载数据集操作:

```
def loadDataset(infile):
   f = open(infile, "r")
   line = f.readline()
   line = line[:-1]
   lines = []
   lines2 = []
   while line: # 直到读取完文件
       line = f.readline() # 读取一行文件,包括换行符
       line = line[:-1] # 去掉换行符,也可以不去
       lines.append(line)
   f.close() # 关闭文件
   lines = lines[:-1]
   for x in lines:
       a,b = x.split("")
       a = float(a)
       b = float(b)
       lines2.append([a,b])
   t = np.array(lines2)
   return t
```

3. 定义 Kmeanscluster 类,及相应的函数:

```
class KMeansCluster():
    def __init__ (self, k=3,initCent = 'random', max_iter = 500):
        self._k = k
        self._initCent = initCent
        self._max_iter = max_iter
        self._clusterAssment = None
        self._labels = None

    def __calEDist(self, arrA, arrB):
        return np.math.sqrt(sum(np.power(arrA - arrB, 2)))

    def __randCent(self, data_X,k):
        n = data_X.shape[1] # 获取特征的维数
        centroids = np.empty((k, n)) # 使用 numpy 生成-一个 k*n 的矩阵, 用于存储质心
        for j in range(n):
            minJ= min(data_X[:,j])
```

```
rangeJ = float(max(data_X[:, j]-minJ))
      # 使用 flatten 拉平嵌套列表(nested list)
          centroids[:, j] = (minJ + rangeJ * np.random.rand(k,1)).flatten()
      return centroids
   def fit(self, data_X):
      m = data X.shape[0] # 获取样本的个数
      # 一个m*2 的维矩阵 , 矩阵第- -列存储样本点所 富的族的素引值,
      # 第二列存储该点与所属族的质心的平方误差
      self._clusterAssment = np.zeros((m, 2))
      if self. initCent == "random" :
          self._centroids = self._randCent(data_X, self._k)
      clusterChanged = True
      for _ in range(self._max_iter):
          clusterChanged = False
          for i in range(m): # 将每个样本点分配到离它最近的质心所属的族
             minDist = np.inf # 首先将 minDist 置为- 个无穷大的数
             minIndex= - 1 # 将最近质心的下标置为-1
             for j in range(self._k): #次迭代用于寻找最近的质心
                 arrA = self._centroids[j, :]
                 arrB = data_X[i, :]
                 distJI = self._calEDist(arrA, arrB) # 计算误差值
                 if distJI < minDist:</pre>
                    minDist = distJI
                    minIndex = j
             if self._clusterAssment[i, 0]!= minIndex or self._clusterAssment[i,
1] > minDist ** 2:
                 clusterChanged = True
                 self. clusterAssment[i, :] = minIndex, minDist**2
          if not clusterChanged: # 若所有样本点所属的族都不改变,则已收敛,结束迭代
             break
          for i in range(self._k): # 更新质心,将每个族中的点的均值作为质心
             index_all = self._clusterAssment[:,0] # 取出样本所属簇的索引值
             value = np.nonzero(index_all == i) # 取出所有属于第i 个簇的索引值
             ptsInClust = data_X[value[0]] # 取出属于第1 个族的所有样本点
             self._centroids[i,:] = np.mean(ptsInClust, axis = 0)
      self._labels = self._clusterAssment[:,0]
      return self._centroids,self._labels
```

4. 主函数:

```
if __name__ == "__main__":
```

```
data_X = loadDataset("data.txt")
   k = 3
   clf = KMeansCluster(k)
   cents,labels = clf.fit(data_X)
   colors = ['b', 'g', 'r', 'k', 'C', 'm', 'y', '#e24fff', '#524C90', '#845868']
   for i in range(k):
       index = np.nonzero(labels == i)[0]
       x0 = data_X[index, 0]
       x1 = data X[index,1]
       y_i = i
       for j in range(len(x0)):
           plt.text(x0[j], x1[j],str(y_i),color = colors[i], fontdict = {'weight':
'bold', 'size': 6})
       plt.scatter(cents[i, 0],cents[i, 1], marker = 'x', color = colors[i], linewidths
= 7)
   plt.axis([-50, 150, -50, 150])
   plt.show()
```

- 5. 新建 dbscan.py;
- 6. 定义加载数据集操作:

```
def loadDataSet(fileName, splitChar='\t'):
    dataSet = []
    with open(fileName) as fr:
        for line in fr.readlines():
            curline = line.strip().split(splitChar)
            fltline = list(map(float,curline))
            dataSet.append(fltline)
        return dataSet
```

7. 定义求欧氏距离、判断是否为邻近点等基本操作;

```
def dist(a, b):
    return math.sqrt(np.power(a-b,2).sum())

def eps_neighbor(a, b, eps):
    return dist(a, b) < eps

def region_query(data, pointId, eps):
    nPoints = data.shape[1]
    seeds = []
    for i in range(nPoints):
        if eps_neighbor(data[:,pointId], data[:,i], eps):
            seeds.append(i)</pre>
```

return seeds

8. 定义 expand_cluster 函数;

```
def expand_cluster(data, clusterResult, pointId, clusterId, eps, minPts):
   seeds = region_query(data, pointId, eps)
   if len(seeds) < minPts:</pre>
       clusterResult[pointId] = NOISE
       return False
   else:
       clusterResult[pointId] = clusterId
       for seedId in seeds:
           clusterResult[seedId] = clusterId
       while len(seeds) > 0:
           currentPoint = seeds[0]
           queryResults = region_query(data, currentPoint, eps)
           if len(queryResults) >= minPts:
               for i in range(len(queryResults)):
                   resultPoint = queryResults[i]
                   if clusterResult[resultPoint] == UNCLASSIFIED:
                       seeds.append(resultPoint)
                       clusterResult[resultPoint] = clusterId
                   elif clusterResult[resultPoint] == NOISE:
                       clusterResult[resultPoint] = clusterId
           seeds = seeds[1:]
       return True
```

9. 定义 dbscan 函数;

10. 定义函数用于绘制散点图;

```
def plotFeature(data, clusters ,clusterNum):
    nPoints = data.shape[1]
    matClusters = np.mat(clusters).transpose()
```

```
fig = plt.figure()
    scatterColors = ['black', 'blue', 'green', 'yellow', 'red', 'purple', 'orange',
'brown']
    ax = fig.add_subplot(111)
    for i in range(clusterNum + 1):
        colorSytle = scatterColors[i % len(scatterColors)]
        subCluster = data[:,np.nonzero(matClusters[:,0].A == i)]
        ax.scatter(subCluster[0,:].flatten().A[0], subCluster[1,:].flatten().A[0],
c=colorSytle, s=50)
```

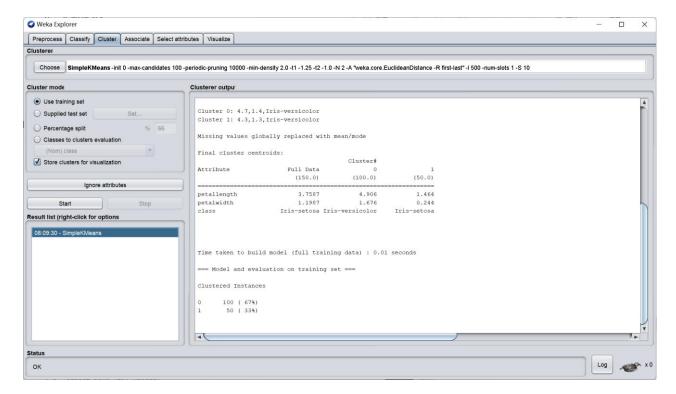
11. 主函数。

```
def main():
    dataSet = loadDataSet('data.txt', splitChar=' ')
    dataSet = np.mat(dataSet).transpose()
    clusters, clusterNum = dbscan(dataSet, 2, 15)
    print("cluster Numbers = ", clusterNum)
    print (clusters)
    plotFeature(dataSet, clusters, clusterNum)
```

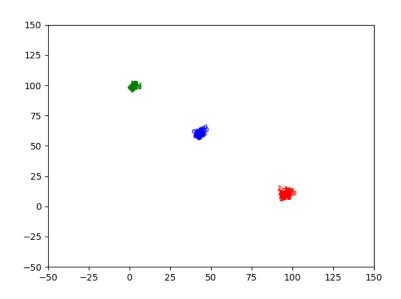
12. 运行该程序,观察运行结果。

七、实验数据及结果分析:

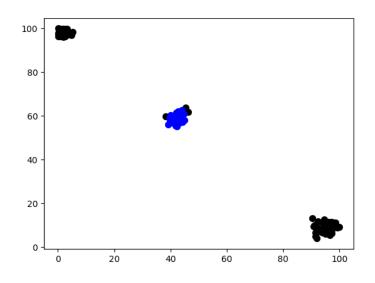
使用 weka 图形界面实现关联规则挖掘,结果如下:



通过运行 kmeans.py,得到如下结果:



可见,通过 kmeans 分类,成功将数据集分成三类,结果符合预期。 通过运行 dbscan.py,得到如下结果:



八、实验结论、心得体会和改进建议:

通过手动实现 kmeans 算法,对 kmeans 分类有了更深刻的理解,对其细节有了更透彻的掌握,进一步强化了理论知识的学习,加深了自己对分类算法的

印象。

无改进建议。